Елисеев В. Б. РТ5-61Б

РК 2, Вариант 4

Задание. Для заданного набора данных (по Вашему варианту) постройте модели классификации или регрессии (в зависимости от конкретной задачи, рассматриваемой в наборе данных). Для построения моделей используйте методы 1 и 2 (по варианту для Вашей группы). Оцените качество моделей на основе подходящих метрик качества (не менее двух метрик). Какие метрики качества Вы использовали и почему? Какие выводы Вы можете сделать о качестве построенных моделей? Для построения моделей необходимо выполнить требуемую предобработку данных: заполнение пропусков, кодирование категориальных признаков, и т.д.

In [1]:

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
```

In [2]:

```
data = pd.read_csv("toy_dataset.csv")
data.shape
```

Out[2]:

```
(150000, 6)
```

In [3]:

```
data.head()
```

Out[3]:

	Number	City	Gender	Age	Income	Illness
0	1	Dallas	Male	41	40367.0	No
1	2	Dallas	Male	54	45084.0	No
2	3	Dallas	Male	42	52483.0	No
3	4	Dallas	Male	40	40941.0	No
4	5	Dallas	Male	46	50289.0	No

In [4]:

```
data.isnull().sum()
```

Out[4]:

```
Number      0
City        0
Gender      0
Age         0
Income      0
Illness     0
dtype: int64
```

Пропусков нет, перейдем к масштабированию данных

Масштабирование

In [5]:

```
from sklearn.preprocessing import MinMaxScaler
num_col = ['Age', 'Income', 'Illness']
for col in data[num_col]:
    plt.hist(data[col],50)
    plt.xlabel(col)
    plt.show()
```

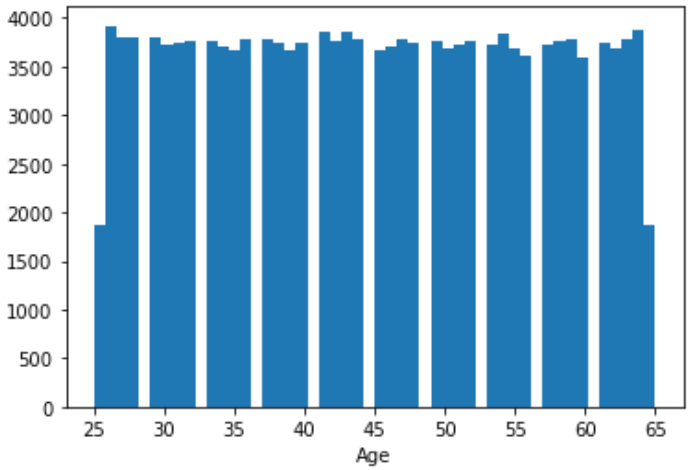

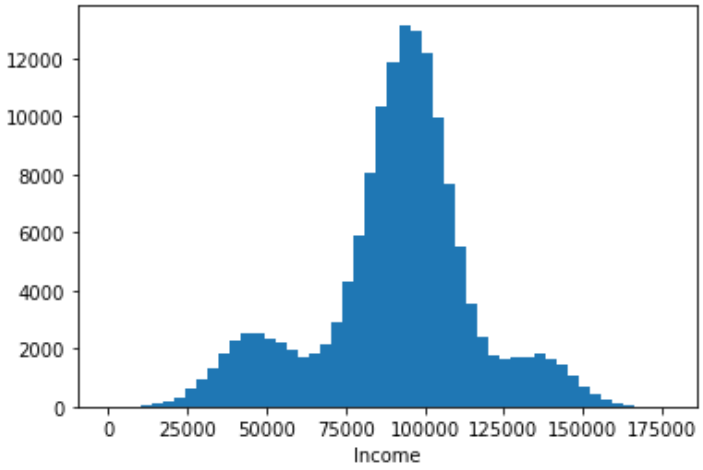

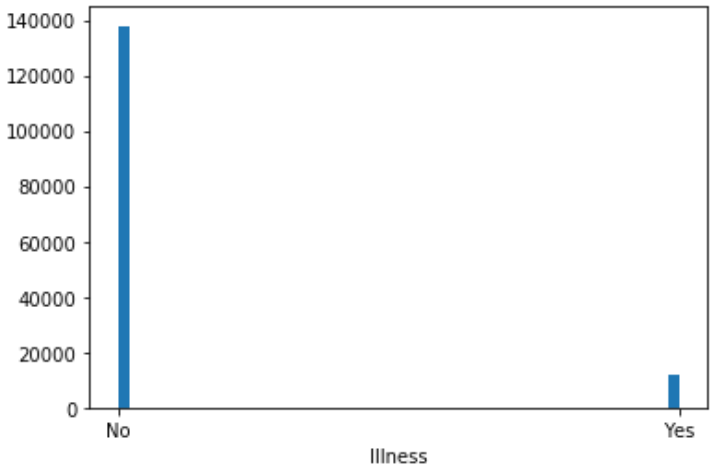

In [6]:

```
from sklearn.preprocessing import LabelEncoder
le = LabelEncoder()
data.loc[:, 'Illness'] = le.fit_transform(data['Illness'])
data['Illness'].head()
```

Out[6]:

```
0    0
1    0
2    0
3    0
4    0
Name: Illness, dtype: int64
```

In [7]:

```
# minmax
sc1 = MinMaxScaler()
for item in num_col:
    data.loc[:, item] = sc1.fit_transform(data[[item]])
```

In [8]:

```
# гистограмма
for col in data[num_col]:
    plt.hist(data[col],50)
    plt.xlabel(col)
    plt.show()
```

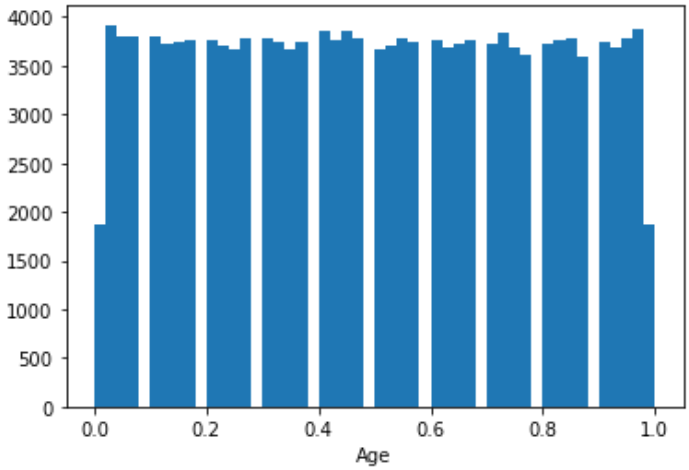

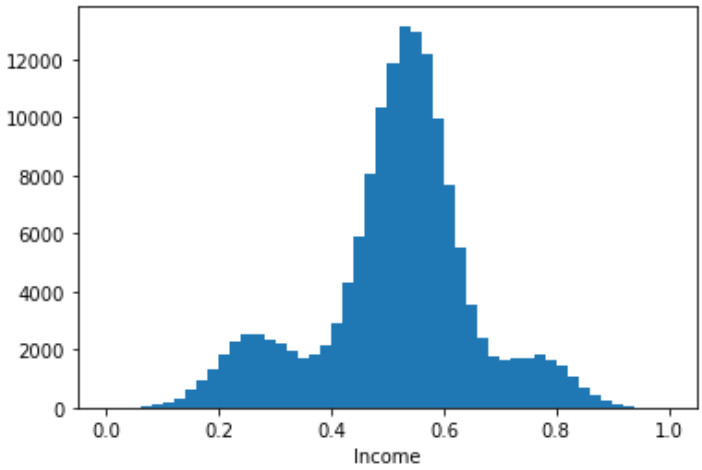

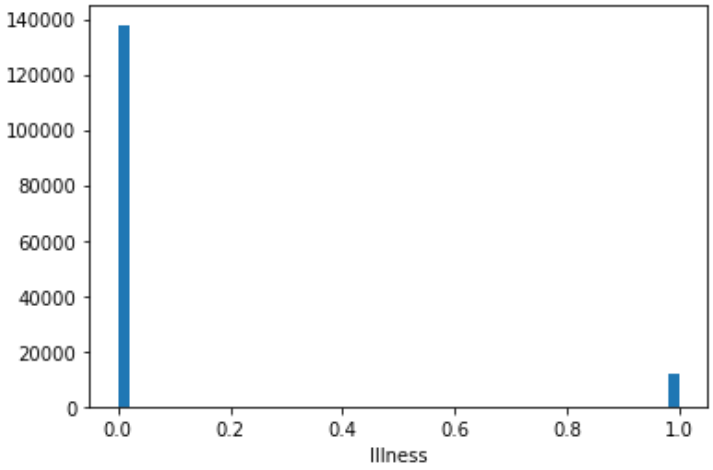

Кодирование категориальных признаков

In [9]:

```
cat_cols = ['City', 'Gender', 'Age']
one_hot = pd.get_dummies(data[cat_cols].astype(str))
```

```
one_hot.head()
```

Out[9]:

	City_Austin	City_Boston	City_Dallas	City_Los Angeles	City_Mountain View	City_New York City	City_San Diego	City_Washington D.C.	Gender_Female	Gend
0	0	0	1	0	0	0	0	0	0	
1	0	0	1	0	0	0	0	0	0	
2	0	0	1	0	0	0	0	0	0	
3	0	0	1	0	0	0	0	0	0	
4	0	0	1	0	0	0	0	0	0	

5 rows × 51 columns

In [10]:

```
# Бинарные значения
data = data.join(one_hot)
data.drop(columns=cat_cols, inplace=True)
```

In [11]:

```
data.head()
```

Out[11]:

	Number	Income	Illness	City_Austin	City_Boston	City_Dallas	City_Los Angeles	City_Mountain View	City_New York City	City_San Diego	...	Age_0.77
0	1	0.230700	0.0	0	0	1	0	0	0	0	...	
1	2	0.257228	0.0	0	0	1	0	0	0	0	...	
2	3	0.298840	0.0	0	0	1	0	0	0	0	...	
3	4	0.233928	0.0	0	0	1	0	0	0	0	...	
4	5	0.286501	0.0	0	0	1	0	0	0	0	...	

5 rows × 54 columns

Построение моделей

In [12]:

```
from sklearn.model_selection import train_test_split
data_train, data_test, data_y_train, data_y_test = train_test_split(data[data.columns.dr
op('Number')], data['Number'], random_state=1)
```

In [ ]:

```
# Дерево решений
from sklearn.tree import DecisionTreeRegressor
dtc = DecisionTreeRegressor(random_state=1).fit(data_train, data_y_train)
data_test_predicted_dtc = dtc.predict(data_test)
```

In [ ]:

```
# Градиентный спуск
from sklearn.ensemble import GradientBoostingRegressor

gboostreg = GradientBoostingRegressor(random_state=10).fit(data_train, data_y_train)
gboostreg_predict = gboostreg.predict(data_test)
```

Оценка качества

Сравним значения средней квадратичной ошибки и коэффициент детерминации:

In [15]:

```
from sklearn.metrics import mean_squared_error, r2_score
# средняя квадратичная ошибка
print('Метрика MSE:\nДерево решений: {}\nГрадиентный бустинг: {}'.format(mean_squared_er
ror(data_y_test, data_test_predicted_dtc), mean_squared_error(data_y_test, gboostreg_pred
ict)))
```

```
Метрика MSE:
Дерево решений: 196526557.47205406
Градиентный бустинг: 97264177.54681845
```

In [16]:

```
# Коэффициент детерминации
print('Коэффициент детерминации:\nДерево решений: {}\nГрадиентный бустинг: {}'.format(r2
_score(data_y_test, data_test_predicted_dtc), r2_score(data_y_test, gboostreg_predict)))
```

```
Коэффициент детерминации:
Дерево решений: 0.8955637143042237
Градиентный бустинг: 0.9483127900630495
```

Оценка качества показывает, что "Градиентный спуск" справляется с задачей лучше,