



Московский государственный технический университет имени Н. Э. Баумана

Факультет «Информатика и системы управления»
Кафедра ИУ5

Отчёт по
Рубежному контролю № 1

Выполнил:
Елисеев В. Б
Группа РТ5-61Б

Москва

2021

Рубежный контроль №1

Вариант 4. Задание 1.

Задача №1.

Для заданного набора данных проведите корреляционный анализ. В случае наличия пропусков в данных удалите строки или колонки, содержащие пропуски. Сделайте выводы о возможности построения моделей машинного обучения и о возможном вкладе признаков в модель.

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")

data = pd.read_csv('toy_dataset.csv', sep=",")

# размер датасета
data.shape

(150000, 6)

# Number: A simple index number for each row
# City: The location of a person (Dallas, New York City, Los Angeles,
# Mountain View, Boston, Washington D.C., San Diego and Austin)
# Gender: Gender of a person (Male or Female)
# Age: The age of a person (Ranging from 25 to 65 years)
# Income: Annual income of a person (Ranging from -674 to 177175)
# Illness: Is the person ILL? (Yes or No)
data.dtypes

Number      int64
City        object
Gender      object
Age         int64
Income     float64
Illness     object
dtype: object

# проверка на пробелы
data.isnull().sum()

Number      0
City        0
Gender      0
Age         0
Income     0
Illness     0
dtype: int64
```

```
# посмотрим первые значения
data.head()

   Number     City Gender  Age  Income Illness
0       1    Dallas   Male   41  40367.0      No
1       2    Dallas   Male   54  45084.0      No
2       3    Dallas   Male   42  52483.0      No
3       4    Dallas   Male   40  40941.0      No
4       5    Dallas   Male   46  50289.0      No

# стат. характеристики данных
data.describe()


          Number            Age        Income
count  150000.000000  150000.000000  150000.000000
mean    75000.500000    44.950200   91252.798273
std     43301.414527    11.572486  24989.500948
min      1.000000    25.000000   -654.000000
25%   37500.750000    35.000000   80867.750000
50%   75000.500000    45.000000  93655.000000
75% 112500.250000    55.000000 104519.000000
max  150000.000000    65.000000 177157.000000

# гистограмма

fig, ax = plt.subplots(figsize=(10,10))
sns.distplot(data['Income'])

/srv/conda/envs/notebook/lib/python3.7/site-
packages/seaborn/distributions.py:2557: FutureWarning: `distplot` is a
deprecated function and will be removed in a future version. Please adapt
your code to use either `displot` (a figure-level function with similar
flexibility) or `histplot` (an axes-level function for histograms).
  warnings.warn(msg, FutureWarning)


<matplotlib.axes._subplots.AxesSubplot at 0x7fb0b63fc450>
```



```
# корреляция  
data.corr()
```

	Number	Age	Income
Number	1.000000	-0.003448	0.410460
Age	-0.003448	1.000000	-0.001318
Income	0.410460	-0.001318	1.000000

```
fig, ax = plt.subplots(figsize=(10,10))  
sns.heatmap(data.corr(), annot=True, fmt='.{6f}')  
<matplotlib.axes._subplots.AxesSubplot at 0x7fb0ae23ddd0>
```



```
# Jointplot для Income, City
sns.jointplot(data=data, x='Income', y='City')

<seaborn.axisgrid.JointGrid at 0x7fb0ada17590>
```

